

A IA tem classe social?

Versão para estudantes de graduação — UFCG Cajazeiras

Nota aos alunos: O texto que segue não é um artigo finalizado. É uma pesquisa em andamento — rascunho de trabalho real, com argumentos ainda sendo testados e refinados. Vocês fazem parte desse processo: os dados produzidos pelo experimento que realizamos em sala — suas respostas, intuições e objeções às questões propostas — serão incorporados à versão final do artigo. Isso significa que esta pesquisa não fala *sobre* vocês a distância; ela se constrói *com* vocês. Leiam, portanto, não como consumidores de um texto acabado, mas como interlocutores de um argumento que ainda está sendo feito.

1. O problema: estrutura que não precisa de intenção

A partir do momento em que sistemas de inteligência artificial passaram a mediar, de maneira crescente, decisões que antes pertenciam a instâncias humanas — triagens de emprego, concessão de crédito, monitoramento escolar, distribuição de benefícios sociais —, uma pergunta tornou-se incontornável: quem, afinal, decide o que esses sistemas consideram normal? Este fato não ocorreu por mero acaso, e a extensão do fenômeno tampouco é acidental. O que importa, contudo, não é apenas a velocidade da expansão — é a opacidade do mecanismo pelo qual esses sistemas operam: eles modelam, orientam e, em alguma medida, fabricam subjetividades, e o fazem tanto mais eficazmente quanto menos visíveis são.

O ponto de partida desta reflexão é, em aparência, simples: o **habitus algorítmico** não precisa atuar como habitus para cumprir sua função. Basta que atue como estrutura. Não é necessário que a IA “jogue o jogo” das desigualdades sociais com intenção ou disposição própria — ela foi treinada por

aqueles que jogam, e isso basta. A questão das disposições da IA é, portanto, uma questão derivada. A questão central é outra: quem a criou? Com quais disposições incorporadas? A partir de qual posição no espaço social?

Para entender: o que é habitus? Conceito central de Pierre Bourdieu, sociólogo francês. Habitus é o conjunto de disposições — formas de ver, sentir, agir e julgar — que internalizamos ao longo da vida por meio da socialização. Não são regras que seguimos conscientemente: são hábitos incorporados tão profundamente que parecem naturais. Um filho de médico e um filho de trabalhador rural não precisam receber ordens diferentes para agir de formas diferentes no mundo — suas disposições já os orientam. O habitus é a estrutura social inscrita no corpo.

2. Por que a explicação institucional não é suficiente — e por que o habitus importa

Ora, uma explicação meramente institucional não dá a dimensão do problema. Dizer que empresas de tecnologia reproduzem desigualdades porque operam sob a lógica do capital — ainda que verdadeiro — deixa em aberto uma dimensão fundamental: a da construção da subjetividade. É precisamente por isso que se torna necessário invocar o conceito de habitus.

O habitus — tal como formulado por Pierre Bourdieu (2009) — é o mecanismo pelo qual a estrutura social se inscreve nos corpos e nas disposições dos agentes, tornando-se, ao longo do tempo, segunda natureza. Ele explica por que engenheiros bem-intencionados, calibrando sistemas de IA com boa-fé manifesta, produzem resultados que alimentam novas formas de desigualdade. Cresceram numa sociedade cuja estrutura constituiu subjetividades imersas no código da desigualdade. E as boas intenções, longe de neutralizar esse processo, revelam-se insuficientes para apagá-lo — o que não é o mesmo que afirmar que as boas intenções o agravam. É uma distinção que importa: o ar-

gumento não é que a virtude piora o resultado, mas que ela não o determina. A intencionalidade individual, neste caso, não é o operador determinante. O *habitus*, sim.

Poderia objetar-se que essa afirmação não é falsificável. Acredita-se que sim, o é: bastaria encontrar um mecanismo pelo qual a formação crítica consistente dos engenheiros produzisse, sistematicamente, sistemas com viés significativamente menor — o que ainda não foi demonstrado de maneira empírica robusta. O argumento não descarta a possibilidade. Apenas afirma que ela é, até o momento, insuficientemente realizada.

Para entender: o que significa “falsificável”? Na filosofia da ciência, um argumento falsificável é aquele que poderia, em princípio, ser refutado por evidências. Se eu digo “todos os corvos são pretos”, basta encontrar um corvo branco para refutar. Um argumento não falsificável — que não pudesse ser contrariado por nenhuma evidência possível — seria dogma, não ciência. A questão aqui é: que tipo de evidência mostraria que as boas intenções dos engenheiros *são* suficientes para neutralizar o viés estrutural? Essa pergunta é legítima, e o argumento precisa enfrentá-la.

3. Por que os engenheiros são o locus relevante — e o que é um engenheiro “estruturalmente inocente”

Os engenheiros que calibram as IAs são o locus analítico relevante — e não por acaso. São eles que foram socializados numa sociedade que viveu quatrocentos e cinquenta anos imersa na escravidão. São eles que aprenderam a habitar a sociedade da negação do racismo estrutural — isso na nação com a maior população negra fora do continente africano (IBGE, 2023). Aprenderam a viver no interior do mito da democracia racial (FERNANDES, 1978), a naturalizar a desigualdade como dado paisagístico da realidade social.

Por mais que portem boas intenções, reproduzem em suas subjetividades essa

estrutura — o habitus da naturalização da desigualdade.

Mas por que eles, especificamente, e não outras categorias igualmente socializadas nessa mesma sociedade? A resposta está na posição que ocupam. Se todas as demais categorias foram socializadas no mesmo solo histórico, os engenheiros são a peça-chave porque estão na posição de criar novas disposições de maneira categórica. Os demais agentes — consumidores, usuários, mesmo reguladores — ainda que exerçam determinada influência, não detêm o que se poderia chamar de poder mágico dos engenheiros: o poder de aprofundar e de fabricar novas formas de disposição, inscritas agora não em corpos humanos, mas em arquiteturas computacionais de alcance civilizatório.

Isso não significa, contudo, que a responsabilidade seja exclusivamente deles. Os engenheiros são os mais responsáveis — e ainda assim operam com uma margem de liberdade limitada. A responsabilidade é, em certa medida, coletiva: partilhada pelos que selecionam dados, pelos que definem requisitos, pelos que avaliam respostas, pelos que regulam e pelos que consomem. O que os distingue é a posição, não a culpa absoluta.

Surge aqui uma categoria que merece atenção: o engenheiro “estruturalmente inocente”. Essa figura não é um tipo empírico raro — é, talvez, a norma. O engenheiro estruturalmente inocente é aquele que acredita, com sinceridade, que seu trabalho não será afetado por seus hábitos e disposições. É muito bem-intencionado, quer fazer o melhor — porém não possui distanciamento nem senso crítico suficientes para enxergar o que não se aprendeu a ver. E, mesmo que os possua, isso não é suficiente para apagar sua história. Como observava Bourdieu a respeito de pessoas que chegam a cargos de chefia: ainda que não queiram repetir os vícios da burocracia e do jogo do poder, acabam por reproduzi-los — porque as disposições precedem a vontade. Queiramos ou não, somos, em alguma medida, escravos de nossas disposições e hábitos. A inocência estrutural não existe como estado permanente; existe, no melhor dos casos, como horizonte regulador que exige trabalho contínuo

sobre si mesmo.

Para entender: o que é “locus analítico”? Locus (do latim: lugar) analítico é o ponto de partida que o pesquisador escolhe para analisar um fenômeno. Não significa que apenas aquele ponto importa — significa que é dali que a análise tem mais poder explicativo. Escolher os engenheiros como locus não é isentar os demais; é reconhecer onde a alavanca estrutural é mais poderosa.

4. Como as disposições estão tecnicamente incorporadas — e por que isso é causalidade, não correlação

Cada dimensão técnica imprime seu próprio viés — e as três convivem, acumulando-se sem se anularem. A seleção de dados, o design da função de perda e o RLHF formam um sistema de reforço mútuo, cada um carregando as marcas da posição social de quem o opera: não são dimensões alternativas, são camadas sobrepostas de um mesmo problema estrutural.

Aqueles que selecionam os dados de treinamento podem favorecer recortes que consideram mais normais, mais lógicos, mais representativos — e o fazem a partir de uma posição no espaço social que raramente é explicitada. Os responsáveis pelo design da função de perda são, em sua maioria, oriundos das classes burguesas dos centros econômicos do planeta, particularmente do hemisfério norte (WEST; WHITTAKER; CRAWFORD, 2019). Essa origem não é um detalhe biográfico irrelevante: é a condição de possibilidade de determinadas escolhas técnicas que passam por neutras.

E há ainda o RLHF — Reinforcement Learning from Human Feedback. Os avaliadores humanos que, nessa etapa, classificam e hierarquizam respostas são, em geral, recrutados na periferia global (PERRIGO, 2023; GRAY; SURI, 2019). E aqui se instala um duplo viés de ordem colonial: seguindo uma lógica análoga à dos selecionadores de dados, tendem a naturalizar aquilo que lhes é familiar, produzindo avaliações enviesadas — mas agora a partir do polo

oposto do espaço social. O viés não está apenas no topo da hierarquia técnica. Está também na base. Está, em síntese, na estrutura.

Poder-se-ia objetar que tudo isso é correlação estrutural disfarçada de causalidade: que o argumento vai de “os engenheiros cresceram numa sociedade desigual” para “seu trabalho alimenta a desigualdade” sem preencher os passos intermediários. A objeção é legítima — e o argumento a enfrenta.

O habitus do engenheiro entra no sistema de IA porque, em cada escolha técnica — quais dados usar, o que o modelo deve aprender a priorizar, como avaliar se está funcionando bem —, ele inconscientemente reproduz os valores, os preconceitos e as normas da sociedade em que foi formado. Essas escolhas viram código, pesos e regras. Quando o sistema é usado em larga escala, ele repete e amplifica essas visões de mundo. Não é correlação: é um processo técnico de tradução do social para o algorítmico. A cadeia causal é identificável em cada etapa — e é precisamente sua rastreabilidade técnica que distingue esse argumento de uma mera analogia estrutural.

Para entender: dados de treinamento, função de perda e RLHF

- **Dados de treinamento:** O conjunto de textos, imagens e informações com os quais a IA aprende. Se esses dados refletem um mundo desigual — e o fazem —, a IA aprende esse mundo desigual como se fosse o normal.
- **Função de perda:** Regra matemática que diz ao sistema quando ele errou e quanto errou. Quem define o que conta como “erro” está, inevitavelmente, definindo o que conta como “acerto” — uma escolha de valor disfarçada de cálculo neutro.
- **RLHF (Aprendizado por Reforço com Feedback Humano):** Fase em que pessoas reais avaliam as respostas da IA e dizem quais são melhores. Quem são essas pessoas? De onde vêm? O que consideram “uma boa resposta”? Essas perguntas têm respostas sociológicas — não apenas técnicas.

5. A objeção estrutural versus individual — e a subjetividade coletiva como resposta

Poderia objetar-se que a análise até aqui oscila entre o estrutural e o psicológico-individual, sem articulá-los de maneira convincente. Não seria descabido objetar isso. Mas acredita-se que Durkheim já respondeu a essa questão, ao menos em seus contornos fundamentais (DURKHEIM, 2007).

A IA não é apenas um aplicativo de uso individual. Ela molda mentalidades coletivas. As duas dimensões — a psíquica e a coletiva — convivem mutuamente, e é precisamente na sua articulação que reside o problema.

Costumo perguntar aos meus alunos, ao início das aulas, o que fazem quando acordam. A maioria esmagadora responde, sem hesitar: vai ao celular. Como sustenta Paulo Ghiraldelli Jr., o capitalismo em sua fase atual não precisa mais recorrer à violência direta, pois conquistou a alma dos explorados — operando, em vez disso, pela captura da subjetividade via infosfera e algoritmo (GHIRALDELLI JR.; CABELO-GHIRALDELLI, 2025). A subjetividade do nosso momento histórico é forjada pelo algoritmo. E esse algoritmo forjou — está forjando — o que se poderia chamar de homens fantasmas: guiados pela ansiedade em duas dimensões simultâneas, a psíquica e individual da falta de sentido, e a coletiva do homem sem propósito, sem territorialidade subjetiva, sem pertencimento.

Este fato não ocorre por mero acaso. A IA tem classe social porque foi feita por quem tem. E porque, ao ser feita assim, reproduz — de maneira estrutural,

não intencional, e por isso tanto mais deletéria — a ordem que a produziu.

Para entender: por que Durkheim aparece aqui? Émile Durkheim, sociólogo francês do século XIX, defendia que os fenômenos sociais não se reduzem a fatos individuais — eles têm existência própria, exterior e coercitiva aos indivíduos. A ansiedade que você sente ao ficar sem celular não é apenas *sua* ansiedade: é um fato social, produzido por uma estrutura que te antecede. Invocar Durkheim aqui é recusar a explicação puramente psicológica — e afirmar que o algoritmo opera em uma dimensão que vai além da soma dos usuários individuais.

Referências (ABNT)

BOURDIEU, Pierre. *O sentido prático*. Petrópolis: Vozes, 2009. [Título original: *Le sens pratique*, 1980]

DURKHEIM, Émile. *As regras do método sociológico*. 3. ed. São Paulo: Martins Fontes, 2007. [Título original: *Les règles de la méthode sociologique*, 1895]

FERNANDES, Florestan. *A integração do negro na sociedade de classes*. 3. ed. São Paulo: Ática, 1978. [1. ed. 1965]

GHIRALDELLI JR., Paulo; CABELO-GHIRALDELLI, Mariangela. *Capitalismo 4.0: Sociedades e Subjetividades*. São Paulo: CEFA Editorial, 2025.

GRAY, Mary L.; SURI, Siddharth. *Ghost Work: How to Stop Silicon Valley from Building a New Global Underclass*. New York: Houghton Mifflin Harcourt, 2019.

IBGE — Instituto Brasileiro de Geografia e Estatística. *Censo Demográfico 2022: características gerais dos moradores*. Rio de Janeiro: IBGE, 2023.

PERRIGO, Billy. Exclusive: OpenAI Used Kenyan Workers on Less Than \$2 Per Hour to Make ChatGPT Less Toxic. *TIME*, 18 jan. 2023. Disponível em:

<https://time.com/6247678/openai-chatgpt-kenya-workers/>

WEST, Sarah Myers; WHITTAKER, Meredith; CRAWFORD, Kate. *Discriminating Systems: Gender, Race and Power in AI*. New York: AI Now Institute, 2019.